

Entre o que o Modelo Constrói e o que o Modelo Busca: Comparação entre LLM-Wiki e RAG

Edital

[EDITAL-PROPP-DICIEN-Nº-07-PIP-2S-2026-27 - Programa de Iniciação à Pesquisa da UFOP](#)

Aluno

Comparação entre RAG e LLM-Wiki para Construção e Consulta de Bases de Conhecimento Verificáveis com Grandes Modelos de Linguagem

Resumo

Grandes Modelos de Linguagem (*Large Language Models* - LLM) têm demonstrado alto desempenho em tarefas de geração textual, resposta a perguntas e apoio à tomada de decisão, mas ainda apresentam limitações relacionadas à atualização do conhecimento, à rastreabilidade das informações utilizadas e à ocorrência de respostas incorretas ou alucinações. Nesse contexto, torna-se relevante investigar a diferença entre a base de conhecimento construída, estruturada em páginas Markdown, mantida e atualizada por LLMs e o conhecimento obtido dinamicamente a partir de fontes externas. Este projeto propõe comparar a abordagem LLM-Wiki, na qual o modelo responde com base no conhecimento construído em forma de Wiki, com a abordagem *Retrieval-Augmented Generation* (RAG), em que documentos recuperados de uma base externa são utilizados para complementar a geração das respostas. Para isso, serão avaliadas perguntas associadas a conteúdos enciclopédicos e resoluções, por exemplo, considerando aspectos como acurácia, atualidade, consistência, capacidade de citação das fontes e robustez diante de diferentes níveis de especificidade das consultas. O desempenho das abordagens será analisado por meio da acurácia e avaliação qualitativa das respostas, buscando identificar em quais cenários a Wiki construída ajuda a responder adequadamente às perguntas e em quais situações a recuperação de informações externas se torna necessária. Ademais, será avaliado onde cada uma começa a falhar ao escalar a quantidade de informação disponível. Assim, este projeto pretende contribuir para o desenvolvimento de sistemas baseados em LLMs mais confiáveis, transparentes e adequados a aplicações que exigem informação verificável.

Palavras-chave

LLM, LLM-Wiki, RAG, Recuperação de informação, Respostas a perguntas, rastreabilidade.

Introdução

Grandes Modelos de Linguagem, ou *Large Language Models* (LLMs), têm se consolidado como uma das principais abordagens contemporâneas para tarefas de geração textual, resposta a

perguntas, sumarização, tradução, organização de informações e apoio à tomada de decisão [1,2]. Esses modelos são capazes de produzir respostas fluentes e contextualmente plausíveis a partir de grandes volumes de dados utilizados em seu treinamento, o que tem impulsionado sua adoção em aplicações acadêmicas, corporativas e educacionais. Entretanto, apesar de seu elevado desempenho em diferentes tarefas de processamento de linguagem natural, LLMs ainda apresentam limitações importantes relacionadas à atualização do conhecimento, à rastreabilidade das informações utilizadas, à dificuldade de explicitar fontes e à possibilidade de produzir respostas incorretas, imprecisas ou não verificáveis [3,4]. Essas limitações tornam-se especialmente críticas em aplicações que exigem confiabilidade, transparência e controle sobre a origem das informações.

Nesse contexto, abordagens baseadas em recuperação de informação têm sido amplamente investigadas como uma forma de mitigar parte dessas limitações. Entre elas, destaca-se a *Retrieval-Augmented Generation* (RAG), na qual documentos externos são recuperados dinamicamente e utilizados como contexto adicional para orientar a geração das respostas [5]. Essa estratégia permite que o modelo acesse informações que não estão necessariamente presentes em seus parâmetros, favorecendo respostas mais atualizadas e fundamentadas em documentos específicos. No entanto, o RAG tradicional tende a operar de forma predominantemente pontual: a cada nova consulta, o sistema recupera fragmentos considerados relevantes e reconstrói a resposta a partir deles, sem necessariamente acumular sínteses, relações, contradições ou interpretações produzidas em consultas anteriores. Assim, embora a recuperação dinâmica amplie o acesso à informação, ela não resolve integralmente o problema da construção progressiva de conhecimento.

Como alternativa a esse paradigma, propostas recentes têm explorado o uso de LLMs não apenas como mecanismos de consulta, mas como agentes de curadoria, organização e manutenção de conhecimento [6,7,8]. A abordagem conhecida como LLM-Wiki (<https://www.tabnews.com.br/andersonlimadev/llm-wiki-como-construir-uma-base-de-conhecimento-o-pessoal-que-evolui-sozinha>) parte da ideia de que o conhecimento pode ser construído de forma persistente em uma base estruturada, geralmente composta por páginas *Markdown* interligadas, resumos, páginas de entidades, sínteses temáticas, índices e registros de atualização. Nessa perspectiva, o LLM não apenas recupera trechos documentais no momento da pergunta, mas participa da ingestão de novas fontes, da extração de informações-chave, da atualização de páginas existentes, da criação de conexões entre conceitos e da identificação de lacunas ou contradições. Dessa forma, a Wiki funciona como uma camada intermediária entre as fontes brutas e o usuário, preservando sínteses acumuladas e permitindo que o conhecimento evolua progressivamente ao longo do tempo.

A diferença entre uma base de conhecimento construída e uma base de conhecimento recuperada dinamicamente levanta questões relevantes para o desenvolvimento de sistemas baseados em LLMs. Por um lado, uma Wiki mantida por LLMs pode reduzir redundâncias, preservar interpretações anteriores, explicitar relações entre conceitos e tornar mais eficiente a consulta a informações já consolidadas. Por outro lado, essa mesma abordagem pode introduzir riscos associados à propagação de erros, à desatualização de páginas, à perda de detalhes presentes nas fontes originais e à dependência da qualidade das sínteses geradas pelo modelo [9]. Em contrapartida, o RAG preserva maior proximidade com os documentos recuperados a cada consulta, mas pode apresentar instabilidade nas respostas, dificuldade de integração entre múltiplas fontes e maior custo computacional ou cognitivo para reconstruir relações complexas repetidamente [10]. Portanto, ainda não está suficientemente claro em quais cenários uma Wiki

construída por LLMs é mais adequada do que a recuperação dinâmica de documentos, nem em que condições cada abordagem começa a falhar.

Este projeto propõe investigar comparativamente a abordagem LLM-Wiki e a abordagem RAG em tarefas de resposta a perguntas baseadas em conhecimento verificável. Para isso, serão consideradas perguntas associadas a conteúdos enciclopédicos e resoluções, avaliando-se diferentes níveis de especificidade, atualidade e complexidade das consultas. Na abordagem LLM-Wiki, o modelo responderá com base em uma base de conhecimento previamente construída, estruturada em páginas Markdown e mantida por operações de ingestão, atualização e verificação. Na abordagem RAG, as respostas serão geradas a partir da recuperação dinâmica de documentos externos relevantes, utilizados como contexto para a geração textual. Essa comparação permitirá analisar não apenas o desempenho final das respostas, mas também a forma como cada estratégia organiza, preserva, recupera e justifica o conhecimento utilizado.

A metodologia proposta envolve a construção de um conjunto de perguntas e respostas de referência, a organização de uma base documental controlada e a implementação de pipelines comparáveis para LLM-Wiki e RAG. As abordagens serão avaliadas considerando critérios como acurácia, atualidade, consistência, capacidade de citar fontes, fidelidade às informações disponíveis e robustez diante de consultas genéricas, específicas ou ambíguas. Além disso, será investigado o comportamento das duas estratégias à medida que aumenta a quantidade de informação disponível, buscando identificar pontos de degradação relacionados à escalabilidade, manutenção da coerência, recuperação de evidências e preservação de informações relevantes. A análise combina métricas quantitativas, como acurácia das respostas, com avaliação qualitativa da completude, verificabilidade e adequação das justificativas produzidas.

Com essa abordagem, o projeto visa contribuir para a compreensão dos limites e potencialidades de bases de conhecimento construídas e mantidas por LLMs em comparação com métodos tradicionais de recuperação aumentada. Espera-se identificar em quais cenários a LLM-Wiki favorece respostas mais consistentes, reutilizáveis e organizadas, bem como em quais situações a recuperação dinâmica de fontes externas se torna indispensável para garantir atualidade, cobertura e rastreabilidade. Assim, o projeto busca avançar no desenvolvimento de sistemas baseados em LLMs mais confiáveis, transparentes e adequados a aplicações que demandam informação verificável, manutenção contínua do conhecimento e maior controle sobre as evidências utilizadas na geração de respostas.

Objetivos

O objetivo do projeto proposto é comparar a abordagem LLM-Wiki com a abordagem RAG em tarefas de resposta a perguntas baseadas em conhecimento verificável, avaliando em quais cenários uma base de conhecimento estruturada em páginas *Markdown* é suficiente para responder adequadamente às consultas e em quais situações a recuperação dinâmica de informações externas se torna necessária. Para atingir o objetivo principal descrito, os seguintes objetivos específicos devem ser atingidos:

- Construir uma base de conhecimento no formato LLM-Wiki, estruturada em páginas Markdown, a partir de conteúdos previamente selecionados.
- Implementar um pipeline baseado em RAG para recuperação dinâmica de documentos externos relevantes às perguntas avaliadas.

- Definir um conjunto de perguntas associadas a conteúdos enciclopédicos e resoluções, considerando diferentes níveis de especificidade, atualidade e complexidade.
- Avaliar a acurácia das respostas geradas pela abordagem LLM-Wiki.
- Avaliar a acurácia das respostas geradas pela abordagem RAG.
- Comparar as abordagens quanto à atualidade, consistência, capacidade de citação de fontes e fidelidade às informações disponíveis.
- Investigar em quais tipos de consulta a Wiki construída contribui para respostas adequadas e em quais casos a recuperação externa se torna indispensável.
- Avaliar como cada abordagem se comporta ao escalar a quantidade de informação disponível.
- Identificar os principais pontos de falha, limitações e vantagens de cada abordagem.

Justificativa/Relevância

Grandes Modelos de Linguagem têm ampliado significativamente as possibilidades de geração textual, resposta a perguntas e apoio à tomada de decisão, mas ainda enfrentam limitações importantes relacionadas à atualização do conhecimento, à rastreabilidade das informações utilizadas e à ocorrência de respostas incorretas ou não verificáveis. Nesse contexto, torna-se relevante investigar estratégias capazes de tornar sistemas baseados em LLMs mais confiáveis, transparentes e adequados a aplicações que exigem controle sobre as fontes de informação. Abordagens baseadas em *Retrieval-Augmented Generation* têm sido amplamente utilizadas para complementar as respostas dos modelos com documentos externos recuperados dinamicamente, permitindo maior acesso a informações específicas e atualizadas. Entretanto, bases de conhecimento construídas e mantidas por LLMs, como a abordagem LLM-Wiki, podem oferecer uma forma alternativa de organizar, sintetizar e reutilizar conhecimento de maneira persistente. Este projeto busca comparar essas duas estratégias, avaliando em quais cenários uma Wiki estruturada em Markdown é suficiente para responder adequadamente às perguntas e em quais situações a recuperação dinâmica de informações externas se torna necessária, contribuindo para o desenvolvimento de sistemas baseados em LLMs mais verificáveis, consistentes e escaláveis.

Essa iniciativa também favorece a criação, formação e desenvolvimento de recursos humanos.

Metodologia

Para o desenvolvimento do projeto, serão disponibilizados pelo laboratório CSILab o espaço físico, servidores e infraestrutura computacional para a implementação, execução e avaliação dos modelos, pipelines e bases de conhecimento propostos.

As principais atividades previstas para o desenvolvimento deste projeto científico são:

- 1.1. Estudo de LLMs e suas principais limitações relacionadas à atualização do conhecimento, rastreabilidade, consistência e ocorrência de alucinações.
- 1.2. Estudo da abordagem RAG, incluindo técnicas de segmentação de documentos, geração de embeddings, indexação vetorial, recuperação de contexto e geração de respostas fundamentadas.
- 1.3. Estudo da abordagem LLM-Wiki, considerando a construção de bases de conhecimento estruturadas em páginas Markdown, atualização incremental, organização de entidades, sínteses temáticas e manutenção de consistência.
2. Definição de uma base documental controlada, contendo conteúdos enciclopédicos ou resoluções a serem utilizados na construção da Wiki e na recuperação por RAG.

3. Construção de uma base de conhecimento no formato LLM-Wiki, organizada em páginas Markdown e atualizada com auxílio de LLMs.
4. Implementação de um pipeline baseado em RAG, utilizando documentos externos indexados e recuperados dinamicamente conforme a consulta do usuário.
- 5.1. Definição de um conjunto de perguntas de avaliação, considerando diferentes níveis de especificidade, atualidade, ambiguidade e complexidade.
- 5.2. Definição das respostas de referência ou critérios de avaliação para comparação das respostas geradas pelas abordagens.
- 6.1. Avaliação da acurácia das respostas produzidas pela abordagem LLM-Wiki.
- 6.2. Avaliação da acurácia das respostas produzidas pela abordagem RAG.
- 6.3. Avaliação qualitativa das respostas considerando consistência, completude, capacidade de citação das fontes, fidelidade às informações disponíveis e clareza da explicação.
- 6.4. Avaliação da robustez das abordagens diante de consultas genéricas, específicas, incompletas ou formuladas de diferentes maneiras.
- 6.5. Avaliação do comportamento das abordagens ao escalar a quantidade de informação disponível na base documental e na Wiki.
- 7.1. Identificação dos cenários nos quais a LLM-Wiki apresenta melhor desempenho, maior organização do conhecimento ou menor custo de recuperação.
- 7.2. Identificação dos cenários nos quais a recuperação dinâmica por RAG se torna necessária para garantir atualidade, cobertura ou rastreabilidade das informações.
8. Comparação final dos resultados obtidos, destacando vantagens, limitações e pontos de falha de cada abordagem.

[LLM Wiki](#)

[kytmanov/obsidian-llm-wiki-local](#)

<https://github.com/swarmclawai/swarmvault>

Referências

- [1] SILVA, Lázaro Q. et al. LLM Text Generation for Service Robot Context. In: 2024 Brazilian Symposium on Robotics (SBR), and 2024 Workshop on Robotics in Education (WRE). IEEE, 2024. p. 25-30.
- [2] VOLK, Martin et al. LLM-based machine translation and summarization for Latin. In: Proceedings of the Third Workshop on Language Technologies for Historical and Ancient Languages (LT4HALA)@ LREC-COLING-2024. 2024. p. 122-128.
- [3] LASKAR, Md Tahmid Rahman et al. A systematic survey and critical review on evaluating large language models: Challenges, limitations, and recommendations. In: Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024. p. 13785-13816.
- [4] MOUSAVI, Seyed Mahed; ALGHISI, Simone; RICCARDI, Giuseppe. LLMs as repositories of factual knowledge: Limitations and solutions. IEEE Transactions on Audio, Speech and Language Processing, 2026.
- [5] ARSLAN, Muhammad et al. A Survey on RAG with LLMs. Procedia computer science, v. 246, p. 3781-3790, 2024.
- [6] MING, Haoliang et al. Retrieval as Reasoning: Self-Evolving Agent-Native Retrieval via LLM-Wiki. arXiv preprint arXiv:2605.25480, 2026.

- [7] HUERTA, Juan M. WiCER: Wiki-memory Compile, Evaluate, Refine Iterative Knowledge Compilation for LLM Wiki Systems. arXiv preprint arXiv:2605.07068, 2026.
- [8] ZHANG, Bailing. Beyond RAG: LLM Wikis as Living Semantic Memory.
- [9] ZHANG, Bailing. Does the wiki grow smarter? A pilot evaluation of LLM-maintained knowledge bases in an exception-dense decision-support task. 2026.
- [10] CHENG, Mingyue et al. A survey on knowledge-oriented retrieval-augmented generation. arXiv preprint arXiv:2503.10677, 2025.